


Memorias del Futuro

De la Amnesia de las RNN a la Evolución con LSTM

De las RNN a LSTM




PODCAST

El Legado: MLP y CNN

Hasta ahora hemos dominado el **Perceptrón Multicapa (MLP)** para datos tabulares y las **Redes Convolucionales (CNN)** para el mundo visual.

- ✓ Procesan información de forma aislada.
- ✓ La muestra actual no tiene relación con la anterior.
- ✓ **Limitación:** Sufren de una "amnesia" estructural innata.



El Punto Ciego: ¿Por qué no bastan?

El mundo real no es una colección de fotos estáticas; es una secuencia fluida.

“

Imaginen un traductor que traduce palabra por palabra sin mirar el resto de la frase; el resultado sería gramaticalmente desastroso.


”



Lenguaje: “Él” depende de qué palabra sigue (verbo, sujeto).



Video: Un frame solo tiene sentido respecto al anterior.



¿Qué es realmente una Secuencia?



Estructura

Serie de datos (imágenes, palabras, sonidos) que siguen un orden específico y significado conjunto.



Variable

Tamaño dinámico: No sabemos cuántas palabras dirá una persona o cuánto durará un audio.



Correlación

Correlación temporal crítica: El estado en el tiempo t depende fuertemente de $t-1$.



En definitiva, los datos secuenciales solo adquieren semántica completa cuando se analizan **en conjunto**; de forma aislada, un carácter o un frame pierden su propósito funcional.





Redes Neuronales Recurrentes (RNN)



NOTACIÓN

x_t : entrada a la RNN en el instante de tiempo "t"
 y_t : salida de la RNN en el instante de tiempo "t"




- **Entradas**
 - $a(t-1)$ La activacion anterior
 - $X(t)$ El dato actual.
- **Salidas**
 - $a(t)$ La activacion actual o Hidden State (estado oculto)
 - $y(t)$ Prediccion actual

Desplegando la Red (Unrolling)

Para entender el entrenamiento, visualizamos la RNN como una cadena de celdas idénticas conectadas horizontalmente.

Este despliegue nos permite aplicar **BPTT**

(**Backpropagation Through Time**): el gradiente fluye desde el final de la secuencia hacia el inicio para ajustar los pesos.



Tipos de Arquitecturas Secuenciales

One-to-Many

Una entrada genera una secuencia
(ej: Image Captioning).

Many-to-One


Secuencia genera una clase (ej:
Análisis de Sentimiento).

Many-to-Many

Secuencia a secuencia (ej:
Traducción Automática).



Image captioning



Traductores

Teacher: why are you
talking during my lesson?

Profesor: ¿por qué hablas
durante mi lección?

Student: why are you
teaching during my
conversation?

Estudiante: ¿por qué dictas
clase durante mi
conversación?



"... aporta nuevos elementos a la
fórmula tradicional, lo que era algo
realmente necesario tras los dos
entremeses anteriores. Eso le
permite hacerse cargo de la propia
premisa que han marcado a los 10
años previos de este universo
cinematográfico, ..."



Clasificación de sentimientos

El Problema del Gradiente Desvaneciente



A medida que la secuencia crece, la información de los primeros pasos se multiplica por pesos pequeños (< 1) repetidamente, haciendo que el gradiente sea casi **cero** al llegar al inicio.

La Memoria a Corto Plazo (Limitación)

Las RNN tradicionales tienen problemas con las **dependencias a largo plazo**.

Mientras mas grande es la extensión de la secuencia el nombre parece mas aleatorio.

Antes de entrenar




Luego de 10 mil iteraciones



Las RNN funcionan bastante bien solo cuando las secuencias de entrada y salida son relativamente cortas.

Evolución: Long Short-Term Memory

La arquitectura diseñada para recordar por largos periodos de tiempo mediante una "autopista de información" protegida por compuertas.




Fueron creadas en 1997 por los investigadores **Sepp Hochreiter** y **Jürgen Schmidhuber**, publicadas en la revista científica *Neural Computation*. La idea nació de una frustración concreta: las redes neuronales recurrentes (RNN) de la época sufrían, donde la red simplemente "olvidaba" información relevante de pasos anteriores cuando las secuencias eran largas.

Hochreiter, siendo aún estudiante en Alemania, había analizado matemáticamente este problema en su tesis de diploma en 1991, y junto a Schmidhuber desarrollaron una solución elegante: introducir una especie de "memoria controlada" dentro de cada neurona, con compuertas que deciden qué información guardar, qué olvidar y qué dejar pasar. Fue como darle a la red un cuaderno de notas interno, en lugar de obligarla a recordarlo todo solo con su estado inmediato.

Anatomía de una LSTM

A diferencia de la RNN simple, la LSTM introduce el **Cell State (Ct)**.

- ✓ **Autopista:** La información fluye por el Cell State con mínimas interacciones lineales.
- ✓ **Puertas (Gates):** Controlan qué se olvida, qué se añade y qué se muestra.



Forget Gate

Output Gate

Input Gate

Diferencias de Arquitectura

Característica	RNN Simple	LSTM
Memoria & Alcance (Naturaleza)	 Volátil, se sobrescribe en cada paso (secuencias muy cortas por desvanecimiento de señal).	 Persistente, “autopista de datos” (Cell State) a miles de pasos.
Mecanismo de Control	→ Nulo (un solo paso lineal pasivo).	 Gating inteligente (3 compuertas activas: olvido, entrada, salida).
Complejidad & Costo	 Estructuralmente simple (rápida de entrenar).	 Estructuralmente compleja, matemáticamente ~4x parámetros por unidad.
Caso de Uso Contextual	Dependencias de muy corto alcance (amnesia funcional).	Gestión inteligente de contextos profundos y dependencias de largo alcance.


Un resumen visual del salto de la amnesia funcional a la gestión inteligente de contextos profundos.

GRU: Eficiencia y Velocidad

Las Gated Recurrent Units (GRU) son una variante moderna que combina el Cell State y el Hidden State.

Arquitectura GRU: Menos compuertas, misma potencia

LSTM
(4 compuertas)



GRU
(2 compuertas)



Update Gate

Decide qué información nueva conservar.



Reset Gate

Decide qué información pasada ignorar.



GRU fusiona las funciones de las compuertas de olvido y entrada de LSTM para decidir de forma más eficiente.



¿Por qué GRU es más eficiente?



1. Solo 2 compuertas: Reset y Update

Menos componentes que calcular → menor complejidad computacional.



2. Más rápidas de entrenar que las LSTM

Menos parámetros y operaciones → entrenamientos más ágiles.



3. Resultados muy similares en la mayoría de las tareas

Rendimiento competitivo con menor costo computacional.



Aproximadamente 25% menos de parámetros que una LSTM equivalente.

Entrena entre 10% y 30% más rápido, especialmente en datos pequeños o medianos donde el riesgo de sobreajuste es mayor.

GRU vs LSTM: Menos complejidad, más velocidad



Parámetros

-25%

Aproximadamente menos que una LSTM equivalente



Velocidad de Entrenamiento

10% - 30%

Más rápida en conjuntos de datos pequeños y medianos



Riesgo de Sobreajuste

Menor

Ideal cuando los datos son limitados



Caso de Uso Ideal

Motores más aerodinámicos

Cuando la velocidad y la eficiencia de memoria son prioritarias



Perspectiva de ingeniería de datos: GRU ofrece el mejor balance entre rendimiento y eficiencia computacional, permitiendo desplegar modelos más rápidos y ligeros sin sacrificar precisión.



¿Dónde viven estas redes?

Las redes recurrentes (como las GRU) están en el corazón de aplicaciones que entienden lenguaje, predicen comportamientos y generan valor.



Asistentes de Voz

Siri y Alexa usan RNN/LSTM para entender el flujo fonético de tu voz y responder con precisión.



Traducción Automática

Google Translate nació usando grandes pilas de capas LSTM para comprender el contexto de oraciones y párrafos.

Hello → Hola → 你好 → ...



Finanzas

Predicción de mercados bursátiles y detección de fraudes temporales mediante patrones secuenciales.



Impacto comprobado en la industria

1

Reconocimiento de Voz (Siri/Google Voice):

La transición a modelos basados en LSTM permitió alcanzar una precisión casi humana. Google reportó una reducción del **49%** en su tasa de error al migrar a estas redes.

2

Traducción Automática (GNMT):

En 2016, el sistema Google Neural Machine Translation sustituyó los métodos estadísticos por una arquitectura profunda de 16 capas de LSTM (8 de codificación y 8 de decodificación), reduciendo los errores de traducción hasta en un **60%**.

3

Sistemas de Recomendación (Spotify):

Plataformas como Spotify utilizan variantes recurrentes (como **GRU4Rec**) para modelar sesiones de escucha para recomendación. A diferencia de un sistema estático, la red de Spotify analiza el orden de las canciones que has escuchado en los últimos 20 minutos para predecir con alta precisión qué "vibe" deseas mantener en la siguiente pista.


El Futuro de la Recurrencia: Evolución y Paralelización



"Aunque los Transformers dominan hoy, las arquitecturas recurrentes están regresando en formas paralelizadas y con mayor eficiencia de memoria."

Próximos Pasos: ¿Cuál elegir?

Sigue este flujo de decisión técnica para elegir la arquitectura recurrente que mejor se adapte a tu próximo proyecto.



Resumen: ¿Cuál elegir?



RNN SIMPLE

- Para secuencias muy cortas.
- Recursos de hardware mínimos.
- Memoria volátil y limitada.



Simplicidad ante todo.



GRU

- Optimiza la eficiencia.
- Rendimiento muy similar a LSTM.
- Significativamente más rápida por su menor número de parámetros.



Eficiencia y velocidad.



LSTM

- Estándar de oro para dependencias de largo alcance.
- Control total sobre qué información persistir o eliminar.



Control y precisión.



La elección correcta depende de tus datos, recursos y objetivos.
Empieza simple, mide resultados y escala cuando sea necesario.

