




1 Fundamentos de Machine Learning

Tipos de Aprendizaje y Regresión Logística

Carrera: Licenciatura en Ingeniería en Ciencia de Datos e Inteligencia de Negocio

Materia: Inteligencia Artificial y Machine Learning para Organizaciones I

Docente: Ronald A. Rivera B.

Nuestros Objetivos de Aprendizaje

1

Identificar y Diferenciar

Aprendizaje supervisado vs. no supervisado.

2

Comprender la Generalización

Overfitting, underfitting, sesgo y varianza.

3


Fundamentos de Regresión Logística

Como modelo base de clasificación.

4

Aplicación Práctica

Conceptos en problemas reales de ciencia de datos.




Introducción al Machine Learning

El Machine Learning es una rama fundamental de la inteligencia artificial que permite a los sistemas aprender y mejorar automáticamente a partir de la experiencia. Utiliza algoritmos sofisticados para analizar grandes volúmenes de datos, extraer patrones y hacer predicciones o tomar decisiones informadas.

- Se aplica en finanzas, medicina, marketing y más.
- Esencial para científicos de datos e ingenieros de inteligencia de negocios.

Tipos Clave de Aprendizaje Automático




Aprendizaje Supervisado

Modelos entrenados con datos etiquetados para predecir.




Aprendizaje No Supervisado

Descubre patrones ocultos en datos sin etiquetas.



Aprendizaje por Refuerzo

Aprende a través de la interacción y la recompensa.



Aprendizaje Profundo

Redes neuronales con múltiples capas para tareas complejas.


En esta sesión, nos centraremos en los dos primeros, fundamentales para su formación.

Aprendizaje Supervisado: Entendiendo los Datos Etiquetados

El aprendizaje supervisado es el paradigma donde el modelo aprende de un conjunto de datos "etiquetados", es decir, pares de entrada y salida conocidos. Su objetivo principal es aprender un mapeo de las entradas a las salidas para poder predecir correctamente

nuevas observaciones no vistas.

- El proceso incluye etapas de entrenamiento, validación y prueba para asegurar su robustez.
- La evaluación se realiza mediante métricas específicas que cuantifican la precisión del modelo.



Aplicaciones del Aprendizaje Supervisado



Clasificación

Asignar categorías discretas a nuevas observaciones (ej. spam/no spam, aprobar/reprobar).




Regresión

Predecir valores numéricos continuos (ej. precio de una casa, temperatura futura).

Un banco utiliza la clasificación para predecir si un cliente pagará un préstamo, basándose en su historial crediticio, ingresos y factores demográficos.

Aprendizaje No Supervisado: Descubriendo Estructuras Ocultas



A diferencia del supervisado, el aprendizaje no supervisado trabaja con datos "no etiquetados". Su meta es descubrir patrones, estructuras inherentes o relaciones ocultas dentro de los datos sin ninguna guía previa sobre las salidas correctas.

- No hay respuestas predefinidas; el enfoque es exploratorio.
- La interpretación humana es crucial para dar sentido a los resultados.

Aplicaciones del Aprendizaje No Supervisado

Clustering

Agrupar datos similares en segmentos lógicos, como la segmentación de clientes en marketing.

Reducción de Dimensionalidad (PCA)

Simplificar conjuntos de datos complejos manteniendo la información esencial, útil para visualización.

Detección de Anomalías

Identificar valores atípicos o inusuales en los datos, crucial para la detección de fraudes.


- ❏ Un equipo de marketing utiliza el clustering para identificar grupos de clientes con comportamientos de compra similares, permitiendo campañas más focalizadas y efectivas.

Supervisado vs. No Supervisado: Una Comparativa

Característica	Aprendizaje Supervisado	Aprendizaje No Supervisado
Datos	Etiquetados	No Etiquetados
Objetivo	Predicción de resultados conocidos	Descubrimiento de patrones y estructuras
Complejidad	Mayor estructura y guía	Mayor flexibilidad e interpretación
Validación	Métricas objetivas y cuantificables	Interpretación subjetiva y análisis exploratorio

Comprender estas diferencias es clave para elegir el enfoque adecuado.

Los Desafíos de la Generalización



La generalización es la capacidad esencial de un modelo de Machine Learning para funcionar eficazmente con datos nuevos e invisibles, más allá de los datos de entrenamiento. Un modelo debe encontrar el equilibrio perfecto entre ajustarse a los datos de entrenamiento y ser lo suficientemente flexible para generalizar bien.

Problemas principales:

Overfitting (sobreajuste): Cuando el modelo memoriza el ruido en los datos de entrenamiento, rindiendo mal con nuevos datos.

Underfitting (subajuste): El modelo es demasiado simple y no logra capturar la complejidad esencial de los datos, tanto de entrenamiento como nuevos.