

Modelos Bayesianos Jerarquicos

De la Incertidumbre a la Estructura: Inferencia avanzada para la toma de decisiones en Ciencia de Datos.




El Desafío de la Realidad

En el mundo real, los datos rara vez son independientes e idénticamente distribuidos (i.i.d.). Los datos poseen **estructuras anidadas** que el modelado clásico ignora a menudo.


- **Estructura multinivel:** Individuos dentro de grupos, grupos dentro de regiones.
- **Dependencias complejas:** El comportamiento de un sujeto está influenciado por su contexto inmediato.
- **Variabilidad latente:** Existen factores no observados que afectan a grupos enteros de manera similar.

Ejemplo Real: Rendimiento escolar. Los alumnos están anidados en clases, y las clases en escuelas. Ignorar la "escuela" como nivel nos lleva a conclusiones erróneas sobre el impacto de un método de estudio.



¿Qué es la Probabilidad Bayesiana?

Bayesian Probability Cycle



Para un Bayesiano, la probabilidad no es solo la frecuencia a largo plazo de un evento, sino un **grado de creencia** o certidumbre.

Componentes Clave:

- **Prior ($P(A)$):** Lo que sabemos (o creemos) antes de ver los datos actuales. Representa nuestro conocimiento previo o teoría.
- **Probabilidad condicional ($P(B|A)$):** Probabilidad de que ocurra B dado que A es cierto. En ingles Likelihood.
- **Probabilidad posterior ($P(A|B)$):** Nuestra creencia actualizada después de confrontar la teoría con la evidencia empírica.

Este ciclo de actualización es lo que permite al modelo "aprender" de manera continua a medida que llega nueva información.

El Teorema de Bayes: El Motor


El teorema describe el proceso racional de cambiar de opinión ante la evidencia. Matemáticamente, lo expresamos como una proporcionalidad:

$$P(A | B) = \frac{P(A) * P(B | A)}{P(B)}$$

Probabilidad a priori (pointing to $P(A)$)
Probabilidad condicional (pointing to $P(B | A)$)
Probabilidad a posteriori (pointing to $P(A | B)$)
Probabilidad total (pointing to $P(B)$)

Consolidación con Diagnóstico Médico:

Imagina una enfermedad rara (Prior bajo). Si el test da positivo (Nueva Evidencia), la probabilidad de estar enfermo aumenta, pero sigue dependiendo fuertemente de la probabilidad inicial. Un test positivo no es una sentencia; es una actualización de la probabilidad.



Frecuentista vs. Bayesiano

Concepto	Frecuentista	Bayesiano
Parámetro	Fijo (Desconocido)	Incierto (Variable Aleatoria)
Datos	Variables (Muestra)	Fijos (Evidencia observada)
Objetivo	Estimación puntual	Distribución de probabilidad


Mientras que el frecuentista confía en el "largo plazo", el Bayesiano cuantifica la incertidumbre en el "aquí y ahora".

¿Frecuentista o Bayesiano?

La diferencia es filosófica más que matemática. ¿Cómo definimos "probabilidad"?

Frecuentista

La probabilidad es la **frecuencia** de resultados a largo plazo.



Frecuentista: Vive en el "¿Qué pasaría si repitiera esto mil veces?"

Bayesiano

La probabilidad es el grado de creencia antes y después de ver los datos (Prior $\Rightarrow$ Posterior)




Bayesiano: Vive en el "¿Qué puedo aprender con los datos que tengo ahora?"

Bayesiano: Vive en el "¿Qué puedo aprender con los datos que tengo ahora?"

Introducción a la Jerarquía

Los modelos jerárquicos (o multinivel) nos permiten modelar la estructura del mundo mediante la estimación de parámetros que dependen de otros parámetros.



Las tres estrategias de "Pooling"

No Pooling

Cada grupo se estima de forma independiente. Ignora que los grupos pueden ser similares.

Riesgo: Sobreajuste en grupos con pocos datos.

Partial Pooling

El equilibrio jerárquico. Los grupos comparten información a través de una distribución común.

Beneficio Robusto ante grupos pequeños.

Complete Pooling

Se asume que todos los grupos son idénticos. Se colapsan los datos en uno solo.

Riesgo: Ignora la diversidad y variabilidad real.

Intercambiabilidad (Exchangeability)

Es el requisito fundamental para el modelado jerárquico. Si no conocemos diferencias previas sistemáticas entre los grupos, debemos tratarlos como "intercambiables". Esto significa que las etiquetas de los grupos no contienen información por sí mismas; lo que importa es la distribución de la cual provienen.

Ejemplo Real: Ensayos Clínicos

En un estudio multihospitalario, asumimos que los pacientes de diferentes hospitales son intercambiables a menos que sepamos que un hospital trata casos mucho más graves. Esto nos permite aprender del promedio general para mejorar la estimación en cada hospital individual.



El Concepto de Hiperparámetro



En un modelo jerárquico, elevamos el nivel de abstracción. Ya no solo estimamos parámetros, sino los parámetros de esos parámetros.

- **Parámetro (θ theta):** Media por grupo. Caracteriza a un grupo específico (ej: media de una escuela).
 - **Hiperparámetro (μ - mu, τ - tau):** Caracteriza la distribución de los parámetros (ej: media global de todas las escuelas y su variabilidad).
- Al estimar los hiperparámetros desde los datos (hiperpriors), el modelo se vuelve autocalibrado, permitiendo que la información fluya desde la población hacia el individuo.

Ejemplo Clásico: Las 8 Escuelas

Un experimento seminal de Rubin (1981) sobre el efecto de programas de entrenamiento para el SAT.

- **Problema:** Algunas escuelas tenían muestras muy pequeñas, produciendo resultados extremos y ruidosos (ej: efecto de +28 puntos).
- **Solución:** El modelo jerárquico aplicó "**encogimiento**".
- **Resultado:** Las estimaciones extremas se movieron hacia la media global. Aprendimos que el efecto real era moderado pero consistente en todas las escuelas.

El Ejemplo de las 8 Escuelas (Rubin, 1981)

Efecto de un programa de entrenamiento en el puntaje SAT




• Estimación del Efecto
+50, +20, 0, ...

• Error Estndar
 $\pm 10, \pm 15, \pm 8, \dots$

Sin Agrupamiento

Modelo Bayesiano
(Partial Pooling)

Agrupamiento Completo



Combina Información


Asume Igualdad

Sin conectar

Balancea

Todo igual

Desde Redes Sociales a Tumores en Ratas



En el contexto de la Probabilidad Bayesiana, las redes sociales pueden entenderse como un sistema de dependencias:

- Prior: Es nuestra creencia inicial sobre si a un usuario le gustará un contenido basándonos en su historial general.
- Likelihood (Probabilidad condicional): Es la probabilidad de que el usuario haga "clic" dado que el contenido pertenece a una categoría específica (como tecnología o deporte).
- Posterior: Es la creencia actualizada; tras observar la interacción del usuario con nuevas publicaciones, el algoritmo ajusta sus recomendaciones en tiempo real.

¿Cómo estimar la probabilidad de tumor en un nuevo grupo de control de 14 ratas si solo 4 presentan tumores?

Uso de Datos Históricos:

Si tenemos registros de 70 experimentos anteriores, estos forman nuestro "Prior" jerárquico. En lugar de confiar solo en las 14 ratas de hoy, usamos la variabilidad histórica para informar el presente.

En investigación farmacéutica, esto reduce drásticamente el número de sujetos necesarios en el grupo de control actual, optimizando costos y ética.

El Desafío Computacional

A medida que añadimos niveles jerárquicos, las integrales matemáticas se vuelven imposibles de resolver analíticamente.

Entramos en el terreno de la simulación.




MCMC: Monte Carlo por Cadenas de Markov

No calculamos la probabilidad; la **muestreamos**. Los algoritmos MCMC exploran la distribución a posteriori mediante "caminatas aleatorias".

- **Metropolis-Hastings:** Acepta o rechaza saltos basándose en la densidad de probabilidad.
- **Muestreador de Gibbs:** Descompone el problema en parámetros individuales.
- **Hamiltonian Monte Carlo:** Usa conceptos de física para explorar eficientemente espacios complejos.

Con suficientes muestras, el histograma de estos puntos converge exactamente a la distribución teórica.



Diagnóstico de Convergencia

¿Cómo sabemos si el explorador (MCMC) tuvo éxito?

Usamos los **Trace Plots** (Gráficas de Oruga) para auditar el modelo.




Usamos los **Trace Plots** (Gráficas de Oruga)

Convergencia: "Oruga Peluda"






Distribución Final



✓ **Convergencia (Salud)**

✗ **Problemas de "Stuck" (Fallas)**

💡 **Rango de Incertidumbre**



💡 Densidad no es un "punto", sino un área de credibilidad Estadística

✓ **Oscilan rápido** alrededor de un **valor central** → "Zona más probable"

✗ **Modelo atrapado, sin mezcla:**

- Falta de datos o
- Mala elección del prior

✓ **Densidad** no es un "punto", sino un **área** de credibilidad Estadística

✓ **En resumen:** Si las gráficas son ruido blanco confía. Si hay patrones, ten cuidado.

¿Podemos confiar en nuestras simulaciones? Necesitamos verificar que las cadenas han explorado bien el espacio.

R $\approx$ 1.0

Estadístico de Gelman-Rubin (R): Compara la varianza entre diferentes cadenas. Si es cercano a 1, el modelo ha convergido.

Traceplots: Visualmente buscamos "orugas peludas" (cadenas mezcladas y estables). Si vemos tendencias o cadenas separadas, el modelo es inestable.

Evaluación del Modelo (WAIC y LOO)

Ajustar bien los datos no es suficiente; queremos **capacidad predictiva**. Comparamos modelos usando criterios de información.

- **WAIC**: Criterio de información de Watanabe-Akaike.
- **LOO**: Validación cruzada "dejar uno fuera".

Estos indicadores penalizan la complejidad excesiva (overfitting). Son fundamentales en Marketing para decidir qué variables realmente impulsan las ventas y descartar el ruido.

Escenario	Valores Relativos	Interpretación y Acción	Ejemplo en Marketing
El Ideal	Bajos y Similares	Buena capacidad predictiva, modelo estable.	Una campaña de email marketing con aumento real de ventas. [cite: e02b66, 57c9c0]
Sobreajuste	WAIC muy bajo,  LOO   alto/con alertas  ($p_{waic} > 0.4$)	El modelo memorizó el ruido de los datos, fallará en el futuro. → Simplificar.	Una variable meteorológica irrelevante que parece correlacionada por azar. [cite: e02b66, 57c9c0]
Inestabilidad	Gran diferencia (Δ) entre modelos competitivos 	→ El modelo con menor valor es significativamente superior.	Elegir entre modelo con 3 niveles (País, Ciudad, Tienda) vs 2 niveles. [cite: 57c9c0]

Factor de Bayes


A diferencia de los p-valores, el Factor de Bayes cuantifica cuánta evidencia hay a favor de una hipótesis competitiva sobre otra.

Es una herramienta de decisión mucho más intuitiva para la alta dirección y para la ciencia rigurosa.

Nos permite decir cosas como: *"Los datos apoyan 10 veces más la hipótesis de que el fármaco funciona (H1) que la hipótesis nula (H0)".*

Guía de Diagnóstico: Interpretación del Factor de Bayes (K)			
Valor de K (BF ₁₀)	Evidencia a favor de H ₁ (Modelo 1)	Descripción de la Evidencia	Ejemplo en Marketing
> 100 	Extrema	✓ H ₁ es más de 100 veces más probable que H ₀ . Soporte contundente.	La segmentación por ciudad predice las ventas mucho mejor que el promedio nacional.
30 a 100 	Muy Fuerte	✓ H ₁ es entre 30 y 100 veces más probable que H ₀ . ⚠ Gran confianza en el modelo.	Un nuevo canal de publicidad tiene un impacto claro y positivo sobre las ventas.
10 a 30 	Fuerte	✓ H ₁ es entre 10 y 30 veces más probable que H ₀ . ⚠ Evidencia sustancial.	La campaña de email marketing generó un aumento notable de conversiones.
3 a 10 	Moderada	✓ H ₁ es entre 3 y 10 veces más probable que H ₀ . ⚠ Evidencia palpable.	Los clientes jóvenes interactúan ligeramente más con la nueva interfaz de la app.
1 a 3 	Anecdótica	✓ H ₁ y H ₀ son casi igual de probables. No hay soporte suficiente.	No hay diferencias significativas en el comportamiento de compra entre hombres y mujeres. [cite: bca6ca]
1 	Nula	✓ H ₁ y H ₀ son exactamente igual de probables. No se puede discriminar.	Una variable aleatoria no tiene relación con el rendimiento de ventas. [cite: bca6ca]
< 1 	A favor de H ₀ (Modelo Nulo)	✓ H ₀ (el modelo simple) es más probable. H ₁ es poco creíble.	El modelo más simple de "promedio nacional" es preferible al modelo complejo de "segmentación por tienda". ✨

Explicabilidad y Ética



A diferencia de las "Cajas Negras" del Deep Learning tradicional, los modelos Bayesianos jerárquicos son intrínsecamente **explicables**.

- Ofrecen una justificación teórica clara de cada conexión.
- Cuantifican la incertidumbre: No solo dicen "A", sino "A con un 85% de probabilidad".
- Permiten incorporar ética mediante Priors que penalicen sesgos conocidos en los datos históricos.

Conclusión: El Futuro es Bayesiano

"La clave es tratar las creencias como hipótesis provisionales sujetas a actualización conforme llegan nuevos datos." — *Nate Silver, The Signal and the Noise*

RESUMEN: LA ESENCIA BAYESIANA

1. FLEXIBILIDAD MENTAL



- Tratar creencias como hipótesis provisionales sujetas a actualización conforme llegan nuevos datos.

2. LA JERARQUÍA COMO FILTRO




- Usar hiperparámetros y *Partial Pooling* para ser honestos con la realidad de los grupos pequeños.

3. TECNOLOGÍA Y ÉTICA



- Navegar el desafío computacional (MCMC) para asegurar capacidad predictiva (WAIC/LOO) y evidencia sólida (Factor Bayes) con responsabilidad.



Navegar la incertidumbre con estructura es el superpoder del Científico de Datos moderno.

Image Sources



https://upload.wikimedia.org/wikipedia/commons/thumb/9/9d/Mental_capacities.svg/1280px-Mental_capacities.svg.png

Source: en.wikipedia.org



<https://i.redd.it/in5fkuz5gyj71.jpg>

Source: www.reddit.com



https://images-provider.frontiersin.org/api/ipx/w=1200&f=png/https://www.frontiersin.org/files/Articles/1578825/fpsyg-16-1578825-HTML/image_m/fpsyg-16-1578825-g001.jpg

Source: www.frontiersin.org



<https://cdn.analyticsvidhya.com/wp-content/uploads/2025/06/Main-image-1-1.webp>

Source: www.analyticsvidhya.com



https://img.freepik.com/premium-vector/black-white-sketch-man-woman-walking-away-from-each-other-diverging-paths_518698-2307.jpg

Source: www.freepik.com



https://blog.tomsawyer.com/hubfs/Blog/2023.03.06.0.NetworkEditor.Circular_1_optimized_100.png

Source: blog.tomsawyer.com

Image Sources



<https://i.ytimg.com/vi/Su-xS5js4-k/hq720.jpg?sqp=-oaymwEhCK4FEIIDSFryq4qpAxMIARUAAAAAGAEIAADIQj0AgKJD&rs=AOOn4CLAh86iQ0rWPmTlItep6JotzANAJF6A>

Source: www.youtube.com




<https://home.snu.edu/~hculbert/design.jpg>

Source: home.snu.edu



<https://www.alpharithms.com/wp-content/uploads/2817/greek-alphabet-26.jpg>

Source: www.alpharithms.com



https://mathleaks.com/mediawiki/images/a/af/Mljsx_Slide_A2_U6_C5_Explore1_1.svg

Source: mathleaks.com



<https://venngage-wordpress.s3.amazonaws.com/uploads/2024/08/Icon-and-Image-Library.jpg>


Source: venngage.com



https://png.pngtree.com/png-clipart/20250116/original/pngtree-circular-black-and-white-maze-design-with-intricate-geometric-patterns-png-image_20250329.png


Source: pngtree.com

Image Sources



<https://www.maths.ox.ac.uk/system/files/media/1.jpg>

Source: www.maths.ox.ac.uk



<https://theoreticalecology.wordpress.com/wp-content/uploads/2011/12/trace-plots1.png>

Source: theoreticalecology.wordpress.com



<https://kirby.datawrapper.de/media/pages/blog/chart-types-guide/0d6c67efed-1750015259/feature-image.png>

Source: www.datawrapper.de



<https://www.learnleansigma.com/wp-content/uploads/2024/02/What-is-Hypothesis-Testing.png>

Source: www.learnleansigma.com



https://miro.medium.com/v2/resize:fit:2000/1*IWl_rOxh7Q_aCXjl-3pdTQ.png

Source: medium.com



https://media.istockphoto.com/id/2168455509/vector/vector-icons-letter-mail-check-email-new-message-information-email-address-business.jpg?s=612x612&w=0&k=20&c=QP852nLXFW6W_QvS0JSdFiFXdDCIU629M3Eb-Rg9QA=

Source: www.istockphoto.com

Image Sources



https://static.vecteezy.com/system/resources/previews/074/051/665/non_2x/line-drawing-of-a-hand-holding-a-magnifying-glass-over-a-network-of-connected-nodes-vector.jpg

Source: www.vecteezy.com



https://static.vecteezy.com/system/resources/previews/060/409/545/non_2x/innovative-tasks-solutions-line-icon-lightbulb-with-jigsaw-puzzle-glowing-insight-sharing-alternative-ideas-isolated-illustration-outline-symbol-simple-linear-drawing-editable-stroke-vector.jpg

Source: www.vecteezy.com