

Redes Neuronales Artificiales


El Motor Detrás de la Revolución Digital: Comprendiendo cómo el software aprendió a "pensar" como nosotros.

COPIANDO A LA NATURALEZA


Las redes neuronales artificiales (ANN) nacen de la ambición de emular el cerebro humano. Se basan en el **conexionismo**: la idea de que la inteligencia surge de la interacción dinámica de billones de unidades simples.

CONCEPTO CLAVE

No programamos reglas rígidas; diseñamos una estructura que permite la emergencia del conocimiento mediante conexiones.



LA NEURONA ARTIFICIAL



Mapeando la imagen a este ejemplo:

Inputs ($x_0, x_1, x_2, \dots$) → Los datos de entrada del estudiante:

- $x_0 = 1$ siempre (es el término de bias, permite desplazar la curva)
- x_1 = horas que estudió
- x_2 = su nota previa en el curso

Pesos ($w_1, w_2, \dots$) → Qué tanto importa cada variable. Un $w_1 = 1.2$ significa que cada hora de estudio "pesa bastante". Los pesos son lo que el modelo **aprende** durante el entrenamiento.

Z (función lineal) → La sumatoria ponderada: $z = b + w_1 \cdot x_1 + w_2 \cdot x_2$. Esto puede dar cualquier número real, de $-\infty$ a $+\infty$.

f (función de activación) → Aquí entra el **sigmoide**: $\sigma(z) = 1/(1+e^{-z})$. Su trabajo es "aplastar" ese número z y convertirlo en una probabilidad entre 0 y 1. Si z es muy positivo → $P \approx 1$. Si z es muy negativo → $P \approx 0$.

Salida y → La probabilidad de que el estudiante apruebe. Si $P \geq 0.5$, clasificamos como "aprueba"; si no, "reprueba". Eso es la clasificación binaria.

La unidad básica es el **elemento procesador**. Recibe múltiples señales de entrada, las combina y genera una respuesta. Es la abstracción matemática de la célula fundamental del sistema nervioso.

- ✓ Entrada (x): Los datos del mundo real.
- ✓ Procesamiento: Suma ponderada de señales.
- ✓ Salida (y): La decisión o mensaje enviado.

Ejemplo: Predecir si un estudiante **aprueba o reprueba** un examen


Primero, la neurona calcula la suma ponderada (z), que en tu imagen es la "Linear function":

$$z = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$$

Luego, aplicamos la **función logística** para transformar cualquier valor de z en un rango entre 0 y 1:

$$f(z) = \frac{1}{1 + e^{-z}}$$


Ejemplo: Predecir si lloverá mañana.



EL PERCEPTRÓN DE ROSENBLATT

En 1957, Frank Rosenblatt creó el **Perceptrón**, la primera red capaz de aprender patrones sencillos mediante el ajuste automático de sus parámetros.

Aunque inicialmente estaba limitado a problemas "linealmente separables", fue la chispa que inició todo el campo de la Inteligencia Artificial moderna.



El Perceptrón

Frank Rosenblatt

Cornell Aeronautical Laboratory)
1957

FIG. 1 — Organization of a biological brain. (Red areas indicate active cells, responding to the letter X.)





FIG. 2 — Organization of a perceptron.



LOS PESOS (W): IMPORTANCIA



Definiendo Relevancia

Cada entrada tiene un peso. El peso determina qué tan importante es esa pista para la decisión final. Si el peso es alto, influye mucho; si es bajo, es casi irrelevante.



$$z = \sum (w_i \cdot x_i)$$



Ejemplo: Tinder

Imagina el algoritmo de Tinder. Los "pesos" son tus preferencias: si el factor "**distancia**" tiene un peso alto, la IA priorizará a personas cerca de ti, ignorando otros rasgos como intereses comunes.


Ejemplo: Predecir si lloverá mañana.



Dependiendo de los pesos la perdida de la probabilidad encontrada vs la real será mas grande o mas pequeña

EL SESGO (BIAS): SENSIBILIDAD

$$z = \omega_1 \cdot x_1 + \omega_2 \cdot x_2 + \omega_3 \cdot x_3 + b$$



El sesgo (b) es un valor adicional que permite ajustar el **umbral de activación** de la neurona. Actúa como un "empujón" constante que ayuda a la red a tomar decisiones incluso cuando las entradas son débiles.

Piénsalo como la sensibilidad de un sensor: un sesgo alto hace que la neurona sea muy "fácil" de activar, mientras que uno bajo la hace más exigente.




Un ejemplo real: Imaginen un algoritmo que decide si darte un crédito bancario.

- Si el banco es **conservador**, pondrá un **Sesgo muy bajo (negativo)**. Esto significa que, aunque tengas buen sueldo y buen historial (buenos pesos), la red necesita 'muchas pruebas' para activarse y decir que sí.
- Si el banco es **agresivo**, pondrá un **Sesgo alto**. La neurona estará 'predispuesta' a dar el crédito incluso con señales débiles.

FUNCIONES DE ACTIVACIÓN

Es una operación matemática no lineal aplicada a la suma de entradas. Sin ella, la red solo resolvería problemas lineales simples (como una recta).

Funciones como **ReLU** o **Sigmoide** permiten a la red capturar patrones complejos y abstractos del mundo real.



CAPAS Y PROFUNDIDAD



Capa de Entrada

Recibe los estímulos del entorno (píxeles de una imagen, palabras de un texto, etc.).




Capas Ocultas

Donde ocurre el procesamiento real y la extracción de características abstractas.



Capa de Salida


Proporciona la respuesta final del modelo (ej: "Es un perro").



DEEP LEARNING: EL PODER DE LO PROFUNDO

Una red se considera "profunda" si tiene múltiples capas ocultas. Cada capa adicional permite al modelo aprender representaciones más abstractas:

La jerarquía de conceptos en redes neuronales profundas



¿Por qué no poner miles de capas a todo?



Costo Computacional

Cada capa extra requiere más memoria y potencia de cálculo (más dinero, tiempo y energía).



Overfitting (Sobreajuste)

Si la red es demasiado profunda, empezará a memorizar, no a aprender.



Desvanecimiento de Gradiente

Sin señal del error, la red dejará de aprender. Es como estudiar de memoria un examen: cualquier cambio y repruebas.

Capas iniciales:

Detectan bordes y líneas.

Capas intermedias:

Identifican formas y texturas.

Capas finales:


Reconocen rostros o conceptos completos.

PROCESO DE ENTRENAMIENTO



Iteración y Ajuste

La red hace una predicción, mide el error y se ajusta para fallar menos. Es un proceso de optimización constante basado en la experiencia de los datos.



Ejemplo: Duolingo

Al principio fallas, la app detecta tu error y te repite la lección ajustando la dificultad hasta que tu "red neuronal mental" domina el patrón del idioma. **Eso es aprendizaje automático.**

Concepto clave: Una red neuronal necesita muchos datos. Sin miles de ejemplos de "perro" y "gato", el ajuste de los pesos nunca será preciso.


"La IA no es inteligente por nacimiento, es inteligente por perseverancia. Repite el ciclo millones de veces en segundos".

PROPAGACIÓN HACIA ADELANTE

Es el camino que recorren los datos desde la entrada hasta la salida. Cada neurona calcula su suma ponderada, aplica su activación y pasa el mensaje a la siguiente capa.

FLUJO DE DATOS


Entrada → Pesos → Activación → Salida. Es la ejecución del modelo para obtener un resultado inmediato.



Flujo general de los datos:

1. **Entrada:** Metemos los datos (por ejemplo, los valores de intensidad de cada píxel de una imagen).
2. **Cálculo en cascada:** Cada neurona de la primera capa recibe esos datos, los multiplica por sus **pesos**, suma su **sesgo** y pasa el resultado por su **función de activación**.
3. **Transmisión:** Ese resultado se convierte en la entrada de la siguiente capa. Este proceso se repite, capa tras capa, como una carrera de relevos.
4. **Resultado:** Al llegar a la última capa, la red nos entrega un número final.

MIDIENDO EL FRACASO



La **Función de Pérdida (Loss Function)** cuantifica la discrepancia entre la predicción y el valor real. Es la brújula que indica qué tan lejos estamos del objetivo.

- Si la pérdida es **alta**, la red cometió un error grave.
- Si la pérdida es **baja**, el modelo está funcionando correctamente.

Mean Squared Error (MSE) para regresión o
Cross-Entropy para clasificación

APRENDIENDO DEL ERROR


El error se propaga **hacia atrás** desde la salida hasta la entrada. Es el "momento de la verdad".

Se calcula matemáticamente cuánto contribuyó cada peso al error final para saber qué "perillas" (pesos) hay que girar para mejorar la próxima vez.

ALGORITMO CLAVE

Utiliza la **Regla de la Cadena** del cálculo para distribuir la culpa del error entre todas las neuronas.

Sin el cálculo eficiente de gradientes, entrenar redes profundas sería matemáticamente imposible o tardaría siglos.



EL OPTIMIZADOR (DESCENSO DE GRADIENTE)

Cómo la red decide en "cuánto" cambiar sus pesos

Si la Función de Pérdida es una montaña, el optimizador es el guía que nos indica en qué dirección bajar para llegar al valle (el error mínimo).

Algoritmos como **Adam** o **SGD** deciden qué tan grandes deben ser los pasos para no pasarse del mínimo pero tampoco tardar demasiado.




EL OBJETIVO: GENERALIZACIÓN

Memorización vs Aprendizaje

No queremos que la IA memorice datos (**Overfitting**), sino que aprenda patrones generales para aplicarlos a situaciones que nunca ha visto antes.

Ejemplo: Filtros de IG

La red no memorizó tu cara específica; aprendió el "concepto" de rostro humano para poder ponerte mostacho sin importar tu ángulo o iluminación.



ESPECIALIZACIÓN ARQUITECTÓNICA




Convolucionales (CNN)

Expertas en visión y procesamiento de imágenes. Detectan patrones espaciales.



Recurrentes (RNN/LSTM)

Diseñadas para secuencias como voz, texto o música. Tienen "memoria" del pasado.



TRANSFORMERS: EL AUGE DE LA GEN-AI

Introducidos en 2017, abandonaron la estructura secuencial por un mecanismo de **"Atención"**.


Permiten procesar cantidades masivas de datos en paralelo, siendo el cerebro detrás de modelos como **ChatGPT** y Claude.

La "Atención" permite a la red enfocarse en las palabras más relevantes de una frase ignorando el ruido.

COMPARACIÓN DE ARQUITECTURAS DE IA

Sección Izquierda: Especialistas y Limitaciones


1. CNN (Visión Espacial):



CNN: Especialistas en visión (espacio). Detecta patrones en rejillas (píxeles).

Analogía: Un Escaner: Mira pedacito por pedacito para encontrar formas.

2. RNN (Memoria Secuencial):




RNN: Especialistas en **memoria (tiempo)**. El orden importa.

Analogía: Una Cadena: Cada eslabón depende del anterior. Pierdes un eslabón, pierdes el sentido.

Sección Inferior: Resumen y Uso Actual**

• Modelos Pre-entrenados:



Usan modelos Pre-entrenados (como GPT, Llama, Claude) y los adaptan. Son grandes y costosos de entrenar desde cero.


• ¿Dónde seguimos usando RNN y LSTM hoy?

1. Sistemas Empotrados (Hardware Limitado):



RNN: Ligera, rápida y eficiente.

2. Series Temporales Puras:



RNN: Predicción minuto a minuto. Sensibilidad a corto plazo.

3. Procesamiento en Tiempo Real (Streaming):



RNN: Procesamiento instantáneo bit a bit.

Sección Derecha: Transformers y 'Entendimiento'**

1. Transformer (Contexto Global):

Entendimiento Profundo



Contexto Global

Los Transformers son los especialistas en el **entendimiento profundo**. Analiza la relación de cada elemento con ***todos*** los demás al mismo tiempo.

Mecanismo Clave: ATENCIÓN:

Usa el mecanismo de ATENCIÓN: Como concentrarse en una persona ignorando el ruido, captando lo relevante.



Contexto Masivo



Recuerdan todo el documento.



Tabla Comparativa


Arquitectura	Tipo	'Superpoder'	Analogía
CNN	Convolutiva	Visión Espacial	Un Escaner
RNN	Recurrente	Memoria Secuencial	Una Cadena
Transformer	Atención	Contexto Global	Un Director de Orquesta

EL RETO DE LA CAJA NEGRA

Las redes profundas son tan complejas que a veces es difícil explicar **por qué** tomaron una decisión. Esto es el problema de la interpretabilidad.

DESAFÍOS ÉTICOS

Sesgo algorítmico, falta de transparencia y la necesidad de una IA que sea justa y explicable para la sociedad.




Tu Futuro con IA

Las redes neuronales han pasado de ser curiosidades académicas a la tecnología más potente de nuestra era.

Entender su funcionamiento te permite no solo usarlas, sino **liderar su implementación ética y estratégica** en tu carrera profesional.



IMAGE SOURCES



https://miro.medium.com/1*SJPacPhP4KDEB1AdhOFy_Q.png

Source: [medium.com](https://miro.medium.com/1*SJPacPhP4KDEB1AdhOFy_Q.png)




<https://towardsdatascience.com/wp-content/uploads/2021/12/1SgJPlfKHwL-qis-aL19Fyg.png>

Source: [towardsdatascience.com](https://towardsdatascience.com/wp-content/uploads/2021/12/1SgJPlfKHwL-qis-aL19Fyg.png)



<https://res.cloudinary.com/dh3e2atop/image/fetch/https://philippschmitt.com/blueprints-for-intelligence/jpg/1960-Rosenblatt.jpg>

Source: [philippschmitt.com](https://philippschmitt.com/blueprints-for-intelligence/jpg/1960-Rosenblatt.jpg)



<https://chartexpo.com/blog/wp-content/uploads/2024/11/linear-regression-graph.jpg>

Source: [chartexpo.com](https://chartexpo.com/blog/wp-content/uploads/2024/11/linear-regression-graph.jpg)



<https://machinelearningmastery.com/wp-content/uploads/2018/10/Line-Plot-of-Rectified-Linear-Activation-for-Negative-and-Positive-Inputs.png>

Source: [machinelearningmastery.com](https://machinelearningmastery.com/wp-content/uploads/2018/10/Line-Plot-of-Rectified-Linear-Activation-for-Negative-and-Positive-Inputs.png)



https://ik.imagekit.io/upgrad1/abroad-images/imageCompo/images/ChatGPT_Image_Nov_20_2025_03_47_56_PMTT18DE.png

Source: [www.upgrad.com](https://ik.imagekit.io/upgrad1/abroad-images/imageCompo/images/ChatGPT_Image_Nov_20_2025_03_47_56_PMTT18DE.png)

IMAGE SOURCES



<https://i.sstatic.net/zylUl.png>

Source: datascience.stackexchange.com




<https://static.vecteezy.com/system/resources/thumbnails/077/331/602/small/circular-arrow-representing-recycling-and-sustainable-economy-loop-vector.jpg>

Source: www.vecteezy.com



https://static.vecteezy.com/system/resources/previews/066/382/846/non_2x/background-data-fiber-optic-line-light-speed-abstract-tech-network-digital-flow-wave-connect-cable-transfer-in-city-systems-hyperspace-swirl-vr-globe-energy-mesh-dynamic-nexus-vector.jpg

Source: www.vecteezy.com



<https://cdn.britannica.com/74/103874-004-4213D8F2.gif>

Source: kids.britannica.com



https://pyimagesearch.com/wp-content/uploads/2021/04/what-is-deep-learning_feature-header.png

Source: pyimagesearch.com



<https://cdn.vectorstock.com/i/500p/79/02/hiker-descending-steep-hill-vector-60837902.jpg>

Source: www.vectorstock.com

IMAGE SOURCES




<https://media.istockphoto.com/id/2178371225/vector/black-keys-silhouettes-old-and-modern-door-opening-elements-house-safety-different-carvings.jpg?s=612x612&w=O&k=20&c=EN8ByNGqrxlbSLnUYKBROxYnUZG1CfAjkhOTbrYkgxE=>

Source: www.istockphoto.com



https://elements-resized.envatousercontent.com/elements-video-cover-images/video-previews/465f5ac8-ee7e-4798-a339-7ff1ac2f6e0f/zsY2L8XQfCj2QgjauHO2_pAV3tsaPQmOqMobOCGFq_Eye%2520Icon%2520Animation_00000.jpg?w=500&cf_fit=cover&q=85&format=auto&s=c0548a379d340727003b2cf92180e6736d603ccb89b8c335f852bf1f327aeda9

Source: elements.envato.com



https://pressbooks.bccampus.ca/collegephysics/wp-content/uploads/sites/29/2016/04/Figure-26_06_01.jpg

Source: pressbooks.bccampus.ca



<https://media.istockphoto.com/id/1947571144/vector/simple-set-of-medical-equipment-vector-solid-icons.jpg?s=612x612&w=O&k=20&c=8eaedILSrcJQ1RS6TOSIfDsdZINbQcEhGKNvoNBIAhA=>

Source: www.istockphoto.com



https://miro.medium.com/1*OaX2vSvAa95XQgAZgRjolw.jpeg

Source: medium.com



<https://media.istockphoto.com/id/2147725129/vector/abstract-mountain-range-landscape-flat-scenery-background.jpg?s=612x612&w=O&k=20&c=xMzSRaA8rle94qqD4NVzk5HBO4QkUNN7SNGXD2XZfEQ=>

Source: www.istockphoto.com