




El Arte de Ver: Introducción a las CNN

De la neurona aislada a la visión artificial

avanzada


Bienvenidos a la evolución del aprendizaje profundo. Hoy pasaremos de entender "datos" a entender "imágenes".

Recapitulando: La Herencia del MLP

¿Dónde nos quedamos?

Las capas ocultas rescatan a la IA de la no-linealidad. El MLP es excelente para datos tabulares y problemas lógicos como el XOR.


Debilidad crítica: El MLP lucha por "ver" el mundo real debido a su arquitectura densa.




El Muro de Cristal: MLP vs Imágenes

- **Explosión de parámetros:** Una imagen de 200x200 RGB genera 120,000 pesos por neurona inicial.

- **Pérdida espacial:** Al "aplanar" la imagen, destruimos la relación entre píxeles vecinos.



El Desafío de la Variación Espacial



Invarianza Traslacional

El MLP tiene cero tolerancia al movimiento. Si el objeto se desplaza un solo píxel, el modelo deja de reconocerlo por su sensibilidad a la posición absoluta.


Biología: La Corteza Visual

Historia Clave para la Evolución de las CNN

Años 50-60s

Hubel y Wiesel

Campos Receptivos:
Neuronas especializadas en detectar características visuales




Hubel y Wiesel

Campos Receptivos:
Neuronas especializadas en detectar características visuales

1989

Yann LeCun

"LeNet":
Primera aplicación práctica de redes convolucionales.



Yann LeCun

2010s

2010s

Dataset Masivo:
Reunió un millón de imágenes etiquetadas para entrenar CNNs



Fei-Fei Li

Dataset Masivo:
Reunió un millón de imágenes etiquetadas para entrenar CNNs.

2012

Alex Krizhevsky
y Geoff Hinton

"AlexNet": CNN profunda y ganadora de la competición Imagenet



2012




Copiando a la Naturaleza (años 1950 a 1960)

Hubel y Wiesel descubrieron que células específicas solo responden a bordes u orientaciones en regiones pequeñas llamadas **campos receptivos**.


¿Qué es una Convolución?

El Proceso de Filtrado para obtener el Feature Map

Deslizamos una pequeña ventana ("filtro" o "kernel") sobre la imagen. Esta ventana realiza multiplicaciones matemáticas para resaltar patrones específicos.




Lo que era la suma ponderada en un MLP en una CNN es la **Convolucion** y la suma de los resultados.



convolución → suma → ReLU

FLUJO DE DATOS EN CNN: OPERACIÓN DE CONVOLUCIÓN.



1. Comienza con la **Imagen de Entrada**.
2. Ilustra la **Operación de Convolución**, donde el filtro (la "lupa inteligente") se desliza y realiza los cálculos matemáticos detallados.
3. Muestra cómo se genera el **Mapa de Características (Feature Map)**.
4. Finalmente, resalta cómo los valores de este mapa se aplanan y se convierten en las **entradas directas para las primeras neuronas** de la red neuronal densa.

El Kernel: Detective de Patrones



Bordes

Filtros especializados en líneas horizontales y verticales.



Curvas

Detectan redondeces y texturas complejas.




Compartidos

El mismo filtro se usa en toda la imagen, reduciendo pesos.

Resalta bordes verticales

Resalta bordes horizontales



Conceptos

- **Especialización:** Cada kernel detecta un rasgo distinto (bordes, texturas, manchas).
- **Eficiencia:** Usar el mismo filtro en toda la imagen ahorra miles de parámetros comparado con el MLP.
- **Aprendizaje de Pesos:** Los valores dentro de estas pequeñas matrices (3x3, 5x5) son los pesos que la red aprenderá durante el entrenamiento.


Mapas de Características

Al deslizar el filtro aplicando ReLU, creamos una nueva imagen llamada **Mapa de Características**. Este mapa resalta dónde aparece el patrón detectado en la imagen original.

Es el "escaneado" digital que permite a la red entender formas geométricas básicas.

Conceptos para consolidar:

- **Representación Abstracta:** El paso de píxeles crudos a mapas de presencia de rasgos.
- **Activación:** Los valores altos en el mapa representan coincidencias fuertes entre el filtro y la imagen.
- **Multiplicidad:** Una sola capa convolucional produce múltiples mapas de características (uno por cada filtro aplicado).




Ajustando: Stride y Padding

CONFIGURACIÓN DEL MOVIMIENTO DEL FILTRO: **STRIDE Y PADDING**


1. EL STRIDE (O ZANCADA): EL PASO DEL FILTRO

STRIDE = 1
(Píxel a Píxel)



Filtro se mueve paso a paso.
Mapa de características más grande.


STRIDE = 2
(Saltos de Dos en Dos)



Filtro salta de 2 en 2.
Reduce drásticamente el tamaño del mapa.


2. EL PADDING (RELLENO): BORDES DE CEROS

SIN PADDING
(Imagen se Encoge)



Píxeles de esquinas se tocan menos veces.
La imagen se encoge.

CON PADDING
(Mantenimiento de Tamaño)




Añade un borde de ceros.
El filtro cubre perfectamente los bordes.
No se pierde información de orillas y mantiene el tamaño original.

Capa de Activación ReLU

$$f(x) = \max(0, x)$$

Eliminación de Ruido


Mantiene señales fuertes y elimina valores negativos (ruido). Añade la no-linealidad esencial para aprender formas complejas.



Pooling: El Resumidor Regional

Max pooling 2x2.

La imagen es reducida a $\frac{1}{4}$ de su tamaño original.




Eficiencia y Control

Reduce el tamaño de los datos para hacer la red más rápida y controlar el sobreajuste.

Max Pooling: Se queda con el valor más alto de una región, capturando la característica más relevante.

Su trabajo no es mirar cada detalle, sino **resumir** lo que sucede en un área pequeña. La técnica más común es el **Max Pooling**. Funciona deslizando una ventana (usualmente de 2x2) y simplemente se queda con el número más grande de esa zona.



Invarianza Espacial y Pooling

¿Por qué es mágico?

Gracias al pooling, la red tolera distorsiones. Si la nariz de un perro se mueve un poco, el Max Pooling captará el mismo valor máximo.


Ejemplo: El reconocimiento facial funciona aunque tengas la cara un poco hinchada por la mañana.

Invarianza Espacial: Flexibilidad Visual en CNNs

Gracias al Max Pooling, la red se adapta a cambios en la posición de patrones clave y aún los reconoce, sin importar que se muevan un poco.



La Jerarquía del Aprendizaje



1

Iniciales

Líneas, puntos y bordes básicos.

2

Medias

Formas y texturas (ojos, ruedas).

3

Profundas

Objetos completos y estructuras.

4

Salida

Decisión semántica final.

Conceptos para consolidar:


- **Jerarquía de rasgos:** La red descompone objetos complejos en partes simples.
- **Profundidad:** A mayor número de capas, mayor es la capacidad de abstracción de la red.
- **Composición:** Las capas profundas no miran la imagen original, miran las combinaciones de las capas anteriores.

Flattening: El Puente de Datos

FLATTENING: DEL MAPA A LA LISTA


- 1. Mapas de Alta Densidad
- 2. MLP solo entiende Listas
- 2. Cripán de estreginda
- 3. "Estiramos" y organizamos Fila por Fila
- 4. Evidencia de Alto Nivel
- 5. Relación Espacial ya no importa

ANTES: MAPAS DE CARACTERÍSTICAS DE ALTA DENSIDAD




Perceptrón Multicapa (MLP) que solo lee listas

PROCESO: EL "APLANAMIENTO" O FLATTENING



DESPUÉS: VECTOR UNIDIMENSIONAL GIGANTE (LISTA DE NÚMEROS)




Preparando la Decisión


Convertimos los mapas de características 3D en un vector largo de una sola dimensión. Esto permite que la información entre a la etapa de clasificación final (MLP).

Fully Connected: El Detective

PROCESO COMPLETO DE UNA CNN: DE PÍXELES A LA DECISIÓN DEL DETECTIVE



Salida Probabilística: Softmax



Softmax normaliza los resultados en probabilidades que suman 1.0 (100%).



Conceptos para consolidar:

- **Probabilidad:** La salida se interpreta como la confianza del modelo en cada clase.
- **Suma Unitaria:** Todas las opciones posibles deben sumar 1.0 (o 100%).
- **Decisión Final:** Generalmente, la clase con el porcentaje más alto es la predicción oficial del sistema.

Flujo Completo de una CNN

Puntos clave para consolidar el conocimiento


- **Jerarquía:** La red construye entendimiento paso a paso, de lo simple a lo complejo.
- **Backpropagation:** Los bloques de Conv + Pooling también son afectados por el back propagation.
- **Resultado:** El flujo termina convirtiendo señales visuales espaciales en una distribución de probabilidad interpretable.



Retropropagación y Pérdida

El Ciclo Completo del Backpropagation en una CNN: De Probabilidades a Filtros

Diferenciando la Corrección de Parámetros: Antes y Después del Flattening



Puntos clave para Consolidar Conocimiento

1. **Afectación Universal:** El backpropagation llega a todos los parámetros entrenables del flujo, asegurando que toda la red aprenda.
2. **Corrección Diferenciada:**
 - En Conv: Actualiza los filtros (kernels) de pesos compartidos que detectan características visuales.
 - En FC (MLP): Actualiza los pesos neuronales de las conexiones densas que realizan el razonamiento lógico.
3. **Jerarquía de Aprendizaje:** Capas iniciales aprenden a detectar bordes y texturas; capas finales aprenden a detectar formas y objetos complejos.
4. **Ciclo de Mejora:** Cada iteración refina los filtros y los pesos, aumentando la precisión del modelo en la clasificación.

CNN en el Mundo Real



 **Autónomos:** Lectura de señales y peatones.


 **Medicina:** Detección de tumores en Rayos X.

 **Seguridad:** ID Facial en smartphones.

El futuro de las CNN

Puntos clave:

- **Evolución:** Las CNN están convergiendo con los Transformers para entender no solo las partes, sino el contexto total de una escena.
- **Capacidad Multiespectral:** A diferencia de la retina humana, la CNN procesa cualquier dato estructurado en cuadrícula (grid-like), incluyendo espectros no visibles y datos multidimensionales como el audio.
- **El Reto Ético/Técnico:** La interpretabilidad y la eliminación de sesgos en los datos de entrenamiento son las fronteras actuales de la investigación.



Las CNN no solo ven números, ven estructuras. Su capacidad de aprender jerarquías las hace la herramienta más potente para entender nuestro mundo visual.

Image Sources



<https://static.vecteezy.com/system/resources/thumbnails/078/489/352/small/artificial-intelligence-eye-icon-with-digital-circuit-board-lines-ai-vision-and-machine-learning-concept-neural-network-eye-illustration-in-black-line-art-style-free-vector.jpg>

Source: www.vecteezy.com



https://upload.wikimedia.org/wikipedia/commons/thumb/4/46/Colored_neural_network.svg/1280px-Colored_neural_network.svg.png

Source: en.wikipedia.org



<https://www.wikihow.com/images/f/fe/Make-a-Paper-Book-Summary.jpg>

Source: www.wikihow.com



https://static.vecteezy.com/system/resources/previews/021/991/015/non_2x/brain-with-magnifier-black-line-icon-human-mind-research-linear-pictogram-neurology-science-exploration-symbol-on-white-background-editable-stroke-isolated-illustration-vector.jpg

Source: www.vecteezy.com



https://miro.medium.com/1*XuOkxaS4OfyljAKMvp4t_Q.jpeg

Source: medium.com



[https://www.rifleman.org.uk/Images/No.8%20Rifle/22in_R_EM1_-_D5\(E\)_4353.G-HR.jpg](https://www.rifleman.org.uk/Images/No.8%20Rifle/22in_R_EM1_-_D5(E)_4353.G-HR.jpg)

Source: www.rifleman.org.uk

Image Sources




https://miro.medium.com/v2/resize:fit:1400/1*MQZACKSBVc3AM_tdHtaAyw.jpeg

Source: pub.towardsai.net



https://i.etsystatic.com/16895977/r/il/9aaa22/2296966395/il_570xN.2296966395_921c.jpg

Source: www.etsy.com



<https://i.sstatic.net/vKHNK.png>

Source: stackoverflow.com



<https://media.easy-peasy.ai/233bf06a-08ca-4300-91be-de06729ecc05/fa8b3b1f-e225-4945-b710-99ec60f617a5.png>

Source: easy-peasy.ai