

De CNN a Modelos Fundacionales

La evolución radical de la visión por computadora: desde el diseño manual de capas hasta el aprendizaje universal a gran escala.

La Era de las CNN

Dejamos de entrenar modelos para realizar una tarea y empezamos a entrenar modelos para que comprendan el mundo. Pasamos de la micro-gestión de píxeles a la comprensión de conceptos.

Conceptos:

- **Sesgo de Localidad:** La arquitectura de las CNN asume intrínsecamente que los píxeles vecinos están relacionados entre sí, procesando la imagen de forma fragmentada en lugar de holística.
- **Jerarquía de Rasgos:** El aprendizaje es progresivo; el modelo descompone objetos complejos en partes simples (bordes -> texturas -> formas -> objetos completos) a través de sus capas.
- **Especialización Rígida:** Aunque son excelentes para tareas específicas (como detectar defectos en una fábrica), las CNN son modelos 'especialistas' que requieren ser reentrenadas casi desde cero si el objetivo o los datos cambian ligeramente.

| Pilares de la Arquitectura CNN



Localidad Espacial

Los filtros operan en áreas pequeñas (píxeles vecinos), capturando bordes, texturas y formas básicas de manera eficiente.

Conceptos:

- **Enfoque en el Detalle:** Las CNN son expertas en patrones locales (texturas y formas básicas).
- **Construcción por Capas:** Funcionan como un lego, armando objetos complejos desde piezas simples.
- **Limitación de Contexto:** Al ser tan locales, les falta la comprensión global que sí tienen los Modelos Fundacionales.



Jerarquía Visual

Las primeras capas detectan líneas simples, mientras que las profundas combinan rasgos para reconocer objetos complejos.



Invarianza

Gracias al *Weight Sharing* y *Pooling*, el modelo puede reconocer un gato sin importar su posición en la imagen.

Limitaciones del Enfoque Clásico

Sesgo Inductivo Rígido: Las CNN asumen que la información relevante es siempre local, dificultando relaciones globales.


Dependencia de Etiquetas: Requieren millones de imágenes clasificadas manualmente por humanos (ImageNet).

Falta de Contexto: Tienen dificultades para entender la escena completa o relaciones entre objetos distantes.

Especialización: Un modelo entrenado para "Carros" no suele servir para "Segmentación Médica" sin re-entrenamiento masivo.

Conceptos:

- **Dependencia Humana:** Las CNN dependen de datos etiquetados manualmente; los modelos fundacionales aprenden solos.
- **Rigidez vs. Flexibilidad:** Las CNN son especialistas de un solo uso; los modelos fundacionales son bases adaptables a cualquier tarea.
- **Falta de Contexto:** Las CNN fallan al conectar elementos distantes en una imagen, algo que la **Atención** de los modelos actuales resuelve.



CAPÍTULO 2

El Gran Cambio

De la Atención al Píxel a la
Visión Global

| ¿Qué es un Modelo Fundacional?

Entrenamiento Masivo

Se entrenan con datasets de escala "Internet" (billones de imágenes) usando **Self-Supervised Learning**, aprendiendo sin etiquetas humanas.

Adaptabilidad Universal

Un solo modelo "fundacional" puede realizar cientos de tareas: clasificación, detección, descripción de imágenes y más.

Conceptos:

1. **Entrenamiento Masivo:** Utilizan datasets a escala de internet para capturar una comprensión global y diversa del mundo.
2. **Aprendizaje Auto-supervisado:** Eliminan la dependencia de etiquetas humanas; el modelo descubre patrones y conceptos de forma autónoma.
3. **Adaptabilidad Universal:** Funcionan como una base generalista que puede ser aplicada a múltiples industrias y tareas visuales sin empezar desde cero.

Hitos en la Evolución

2012

AlexNet

Inicio de la era Deep Learning con CNNs.

2017

Transformers

Nace la arquitectura de atención en NLP.

2020

Vision Transformer

Los Transformers superan a las CNN en visión.

2021+

CLIP / SAM


Modelos que entienden conceptos y formas.

Conceptos:

- **2012 vs. 2020:** El dominio de las CNN fue largo, pero los Transformers (ViT) cambiaron las reglas al procesar imágenes como secuencias de información.
- **Escalabilidad:** El gran salto se dio al descubrir que, a diferencia de las CNN, los nuevos modelos mejoran infinitamente cuanto más información les des.
- **Entendimiento Semántico:** Los modelos actuales (como CLIP) conectan imágenes con palabras, permitiendo una comunicación natural entre humano e IA.

1. CLIP (OpenAI): El puente entre el Lenguaje y la Visión

Alinea texto e imágenes en el mismo espacio matemático



¿POR QUÉ ES IMPORTANTE?

Hizo que la visión fuera "direccionable por lenguaje".

En lugar de etiquetas fijas, CLIP aprende el significado al ver millones de pares imagen-texto.



EL GRAN HITO: TRANSFERENCIA ZERO-SHOT

Puede identificar lo que nunca ha visto, solo con una descripción en texto.



IMPACTO

Base de herramientas como DALL-E o Stable Diffusion.

CLIP entiende que la palabra "perro" y la imagen de un perro representan el mismo concepto.




2. SAM (Meta AI): El "Bisturí Digital" Universal

El modelo que puede segmentar cualquier objeto en cualquier imagen.



EL GRAN HITO: MODELO BASADO EN INSTRUCCIONES

Das una instrucción visual (prompt) y SAM recorta el objeto al instante, incluso en dominios para los que no fue entrenado.



IMPACTO

Ha democratizado el análisis visual complejo. Permite separar objetos del fondo con un solo clic en cualquier industria, sin necesidad de miles de horas de etiquetado manual.



Un clic. Cualquier objeto. Cualquier imagen.


Vision Transformers (ViT)

La arquitectura ViT rompió la hegemonía de las CNN al tratar la imagen como una secuencia de datos.


Image Patching: La imagen se divide en parches (como palabras).

Atención Global: Cada parche puede "hablar" con cualquier otro, sin importar la distancia.

Escalabilidad: A mayor cantidad de datos, mayor es su superioridad sobre las arquitecturas tradicionales.




Modelos Emblemáticos Actuales



CLIP (OpenAI)

Alinea texto e imagen. Permite buscar imágenes con lenguaje natural y clasificación Zero-shot.



SAM (Meta AI)

Segment Anything Model.
Puede recortar cualquier objeto en cualquier imagen sin entrenamiento previo.



Generativos

Modelos como Stable Diffusion usan estas bases para crear arte visual desde simples frases.

Comparativa: CNN vs Fundacionales

Atributo	CNN Tradicional	Modelo Fundacional (ViT/Hybrid)
Relación Espacial	Local (Vecindad)	Global (Toda la imagen)
Supervisión	Supervisada (Etiquetas manuales)	Auto-supervisada (Sin etiquetas)
Transferibilidad	Baja (Requiere <i>Fine-tuning</i>)	Alta (Capacidad <i>Zero-shot</i>)
Computación	Moderada	Extrema (Requiere clusters de GPU)

| Ventajas y Desafíos de la Transición



Nota: Los porcentajes reflejan el impacto relativo en comparación con las arquitecturas CNN previas.

¿Preguntas?

El futuro de la visión artificial ya no se construye píxel a píxel, sino a través de la comprensión universal del mundo visual.



| Image Sources



https://miro.medium.com/1*7_BCJFzekmPXmJQVRdDgwg.png

Source: nafizshahriar.medium.com



<https://theaisummer.com/static/60c2cbe8edb845502c8bbc3b9e88791d/ee604/vision-transformer.png>

Source: theaisummer.com



<https://images.ctfassets.net/kftzwdyauwt9/fbc4f633-9ad4-4dc2-3809c22df5e0/0bd2d5abf90d052731538613e4a42668/overview-a.svg>

Source: openai.com



https://miro.medium.com/v2/resize:fit:1400/1*pGcf9T0uHGSPMnziPAKvvg.png

Source: medium.com



https://www.mdpi.com/BDCC/BDCC-10-00094/article_deploy/html/images/BDCC-10-00094-g001.png

Source: www.mdpi.com